Создание кластера из виртуальных машин

Проект по информатике

Стафеев И.А., Голованов Д.И., Шарыпов Е.А.

Санкт-Петербург, 2023

О чем лабораторная

Цель: развертывание кластера из виртуальных машин с установленной на них распределенной файловой системой, чтобы созданный кластер мог служить средством обработки больших данных в соответствии с парадигмой распределенных вычислений MapReduce.

Задачи

- 1. Придумать практическую задачу, решение которой может быть осуществлено с помощью кластера
- 2. Создать и настроить ВМ для установки РФС
- 3. Установить РФС
- 4. Написать скрипты для MapReduce-задачи
- 5. Провести несколько раз обработку входных данных, доказав работоспособность кластера

Почему именно такая тема и цель

- Охватывает множество тем из изученного курса информатики
- Это интересно и нескучно
- У нас имеется небольшой опыт работы в этой сфере

Немного теории

MapReduce - модель распределённых вычислений. Мар – предварительная обработка данных, Reduce – свертка данных

Apache Hadoop - это инструмент для распределенного хранения данных (HDFS + YARN)

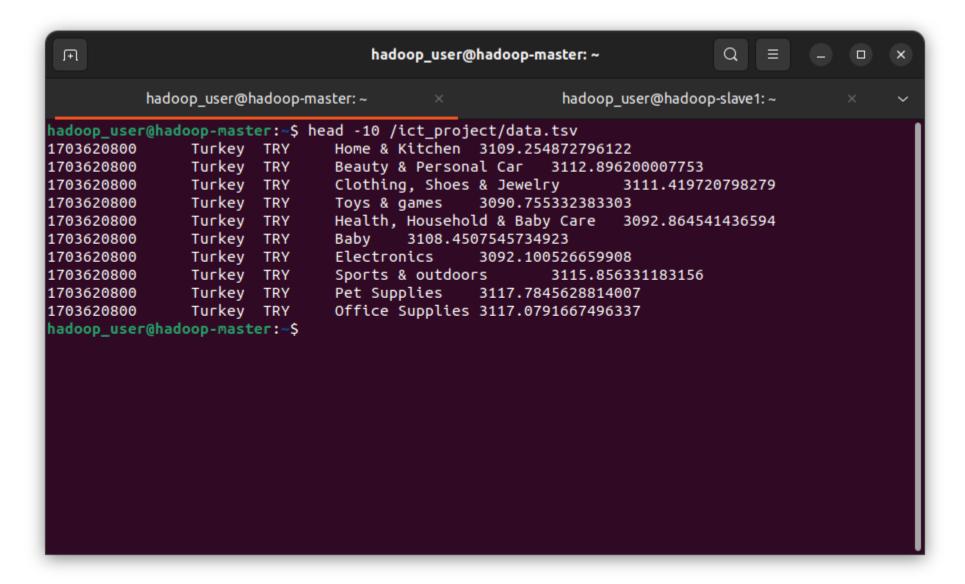
Apache YARN - система планирования заданий и управления кластером

Apache Airflow - инструмент для оркестрации данных и построения **DAG**'ов – представления задач работы в виде графа

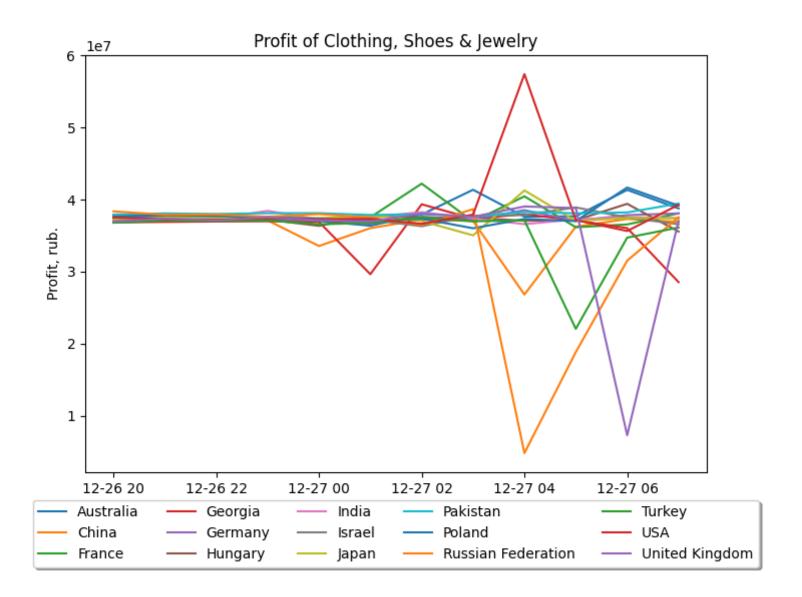
Практическая задача

Преобразование данных о покупках. Раз в 20 минут подсчитывать выручку в рублях и строить график распределения выручки по странам для категории товаров с наибольшей выручкой

Датасет



Хотим



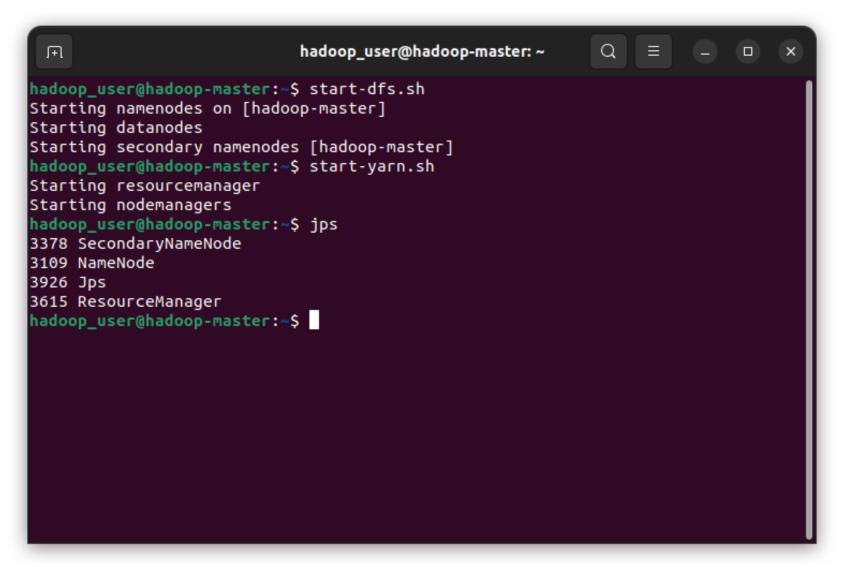
Этап 0

- Создание трех ВМ и подключение в одну сеть NAT
- Создание между ними SSH-подключения
- Установка Java

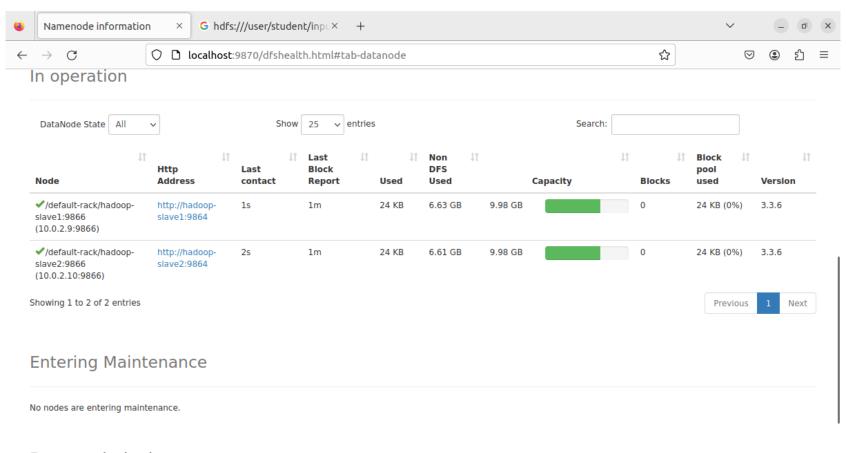
Этап 1

- Установка и конфигурация HDFS
- Форматирование и запуск распределенной файловой системы на кластере

Запуск HDFS



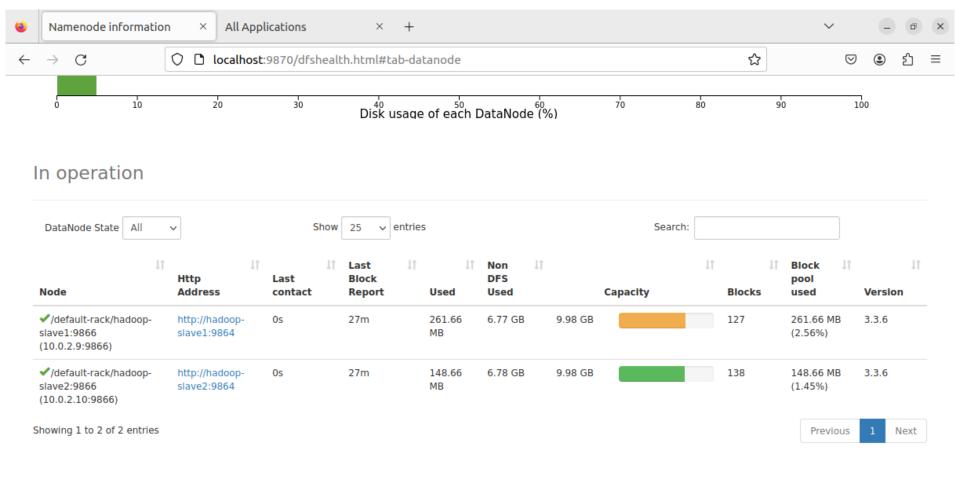
Рабочие ноды кластера



Decommissioning

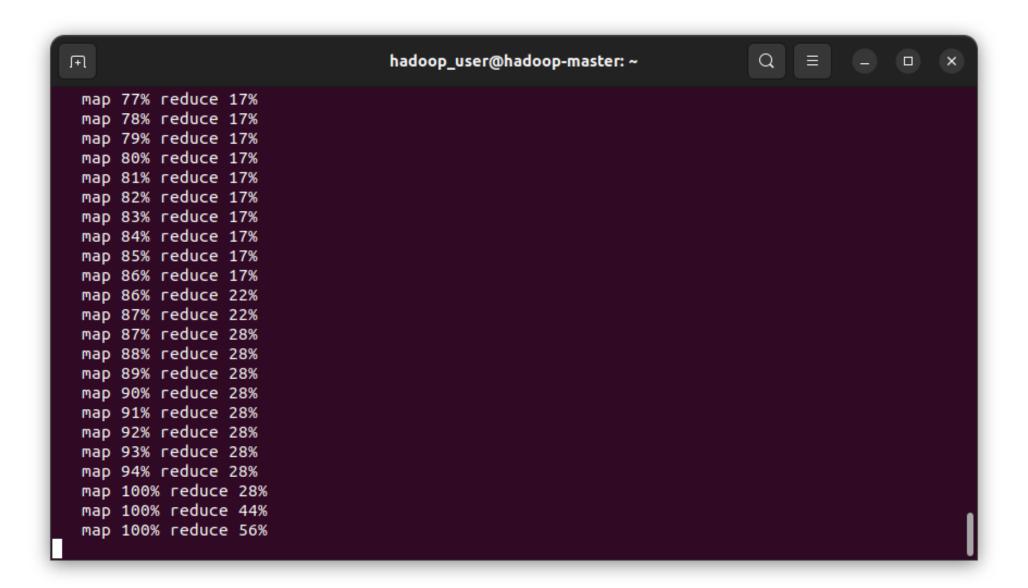
Этап 2

- Создание скрипта для получения валют
- Создание скрипта с map и reduce функциями
- Создание скрипта для визуализации
- Последовательный запуск скриптов над кластеров



Entering Maintenance

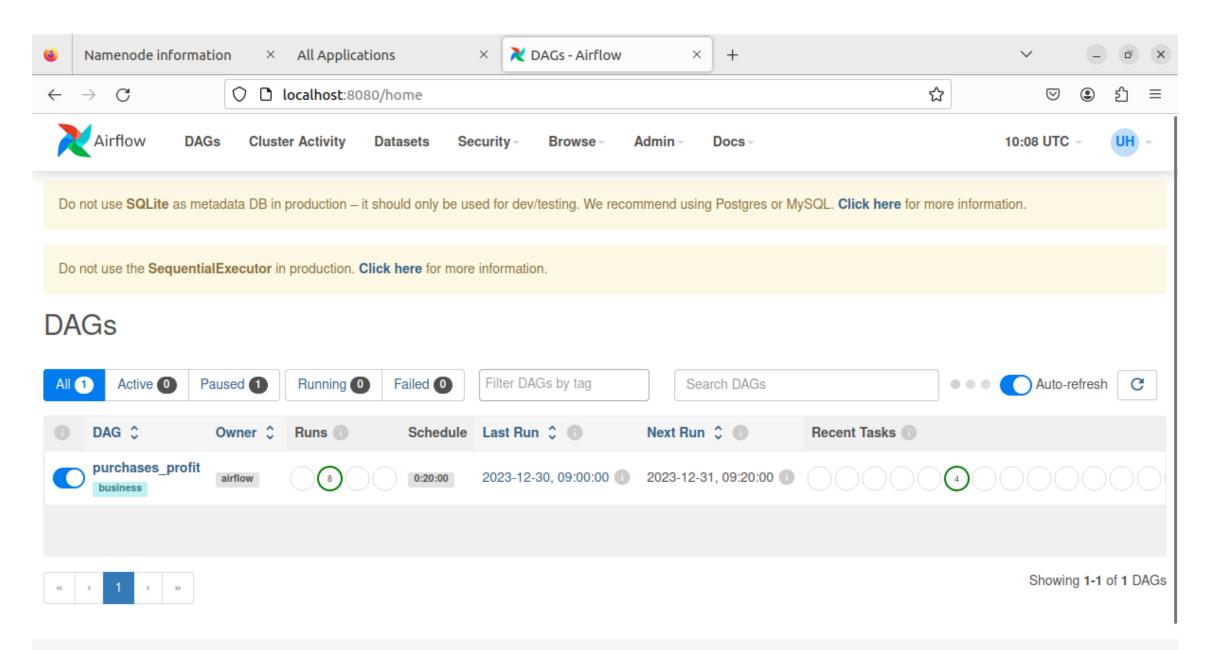
```
hadoop user@hadoop-master: ~
hadoop_user@hadoop-master:~$
hadoop user@hadoop-master:~$ lab/get currencies.sh
            % Received % Xferd Average Speed Time
 % Total
                                                       Time
                                                                Time Current
                                Dload Upload Total Spent
                                                                Left Speed
                                           0 --:--:-- 10455
100 2844
            0 2844
                             0 10472
hadoop_user@hadoop-master:~$ python3 lab/mapred script.py --currencies lab/currencies.json -r
hadoop hdfs:///user/student/input/data.tsv > lab/output.tsv
No configs found; falling back on auto-configuration
No configs specified for hadoop runner
Looking for hadoop binary in /usr/local/hadoop/bin...
Found hadoop binary: /usr/local/hadoop/bin/hadoop
Using Hadoop version 3.3.6
Looking for Hadoop streaming jar in /usr/local/hadoop...
Found Hadoop streaming jar: /usr/local/hadoop/share/hadoop/tools/lib/hadoop-streaming-3.3.6.j
aг
Creating temp directory /tmp/mapred script.hadoop user.20231226.204537.922149
uploading working dir files to hdfs:///user/hadoop user/tmp/mrjob/mapred script.hadoop user.2
0231226.204537.922149/files/wd...
Copying other local files to hdfs:///user/hadoop user/tmp/mrjob/mapred script.hadoop user.202
31226.204537.922149/files/
Running step 1 of 1...
  packageJobJar: [/tmp/hadoop-unjar2683409111838308545/] [] /tmp/streamjob628156531139366329.
iar tmoDir-null
```



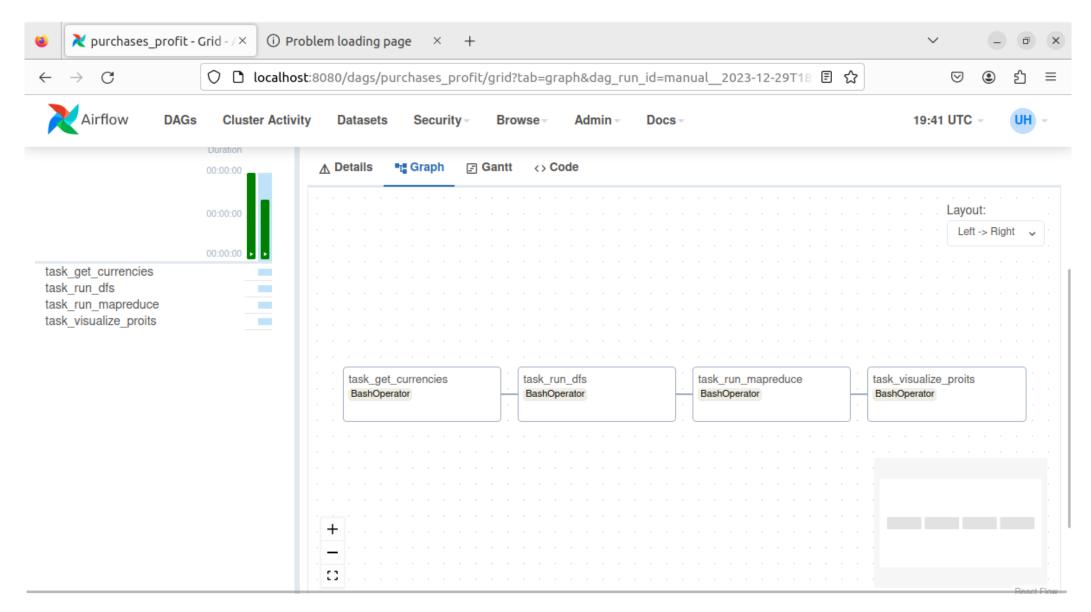
```
Q =
                                  hadoop_user@hadoop-master: ~
 ſŦÌ.
               CONNECTION=0
               IO ERROR=0
               WRONG LENGTH=0
               WRONG MAP=0
               WRONG REDUCE=0
job output is in hdfs:///user/hadoop user/tmp/mrjob/mapred script.hadoop user.20231226.204537
.922149/output
Streaming final output from hdfs:///user/hadoop user/tmp/mrjob/mapred script.hadoop user.2023
1226.204537.922149/output...
Removing HDFS temp directory hdfs:///user/hadoop user/tmp/mrjob/mapred script.hadoop user.202
31226.204537.922149...
Removing temp directory /tmp/mapred script.hadoop user.20231226.204537.922149...
hadoop_user@hadoop-master:~$ head -10 lab/output.tsv
["2023-12-26T20", "Australia", "Baby"] 37507092.75928125
["2023-12-26T20", "Australia", "Beauty & Personal Car"] 37507429.66715513
["2023-12-26T20", "Australia", "Clothing, Shoes & Jewelry"] 37505669.50929021
["2023-12-26T20", "Australia", "Electronics"] 37507901.240210295
["2023-12-26T20", "Australia", "Health, Household & Baby Care"] 37507723.693394884
["2023-12-26T20", "Australia", "Home & Kitchen"] 37506749.883878775
["2023-12-26T20", "Australia", "Office Supplies"] 37507907.86400904
["2023-12-26T20", "Australia", "Pet Supplies"] 37505637.796687685
["2023-12-26T20", "Australia", "Sports & outdoors"] 37506709.31300333
["2023-12-26T20", "Australia"<u>,</u> "Toys & games"] 37507649.93278636
hadoop user@hadoop-master:~S
```

Этап 3

- Установка и настройка Airflow
- Создание DAG для выполнения созданных ранее скриптов
- Выполнение DAG run несколько раз для доказательства работоспособности



DAG



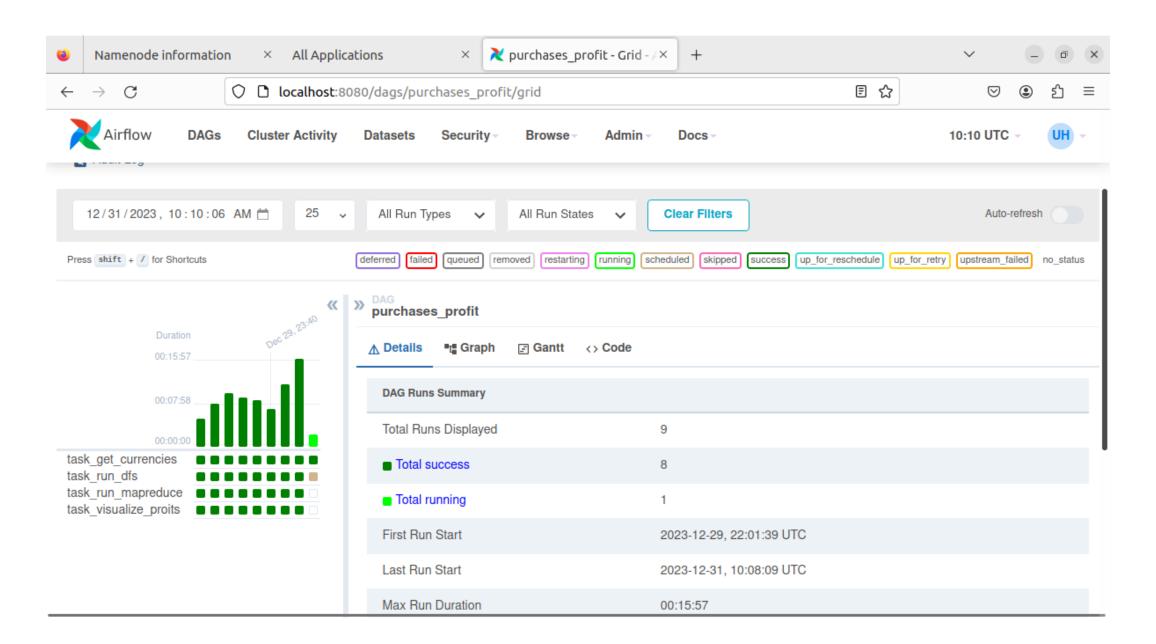
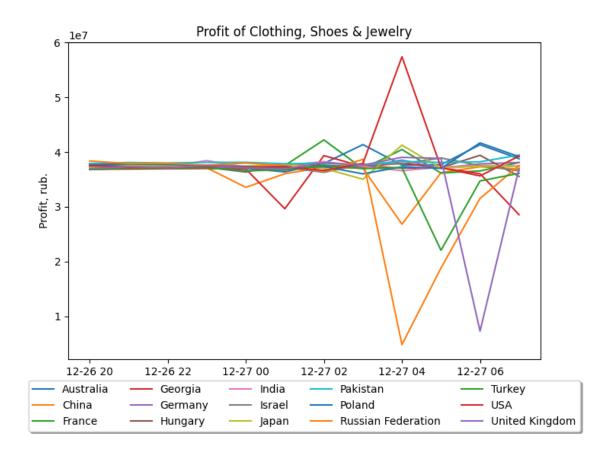
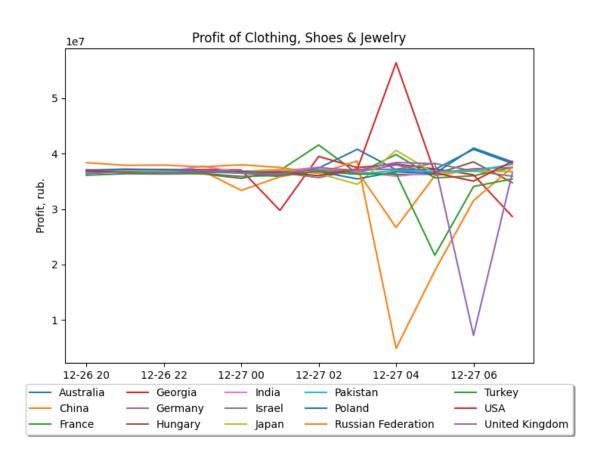


График за 7 и 8 прогон





(разница есть)

Польза лабораторной

- Закрепление знаний по работа с терминалом, Bash, сетевыми службами, виртуализацией
- Навыки создания и настройки кластера
- Навыки оркестрации данных
- Навыки простого анализа данных
- Навыки работы с MapReduce

Источники

- 1. Хабр. Big Data от A до Я. Часть 1: Принципы работы с большими данными, парадигма MapReduce [Электронный ресурс]. URL: https://habr.com/ru/articles/267361/ (дата обращения: 30.12.2023)
- 2. Tom White. Hadoop: The Definitive Guide [Электронный ресурс]. URL: <u>ссылка</u> (дата обращения: 30.12.2023)
- 3. Apache Hadoop 3.3.6 Documentation [Электронный ресурс]. URL: https://hadoop.apache.org/docs/stable/ (дата обращения: 30.12.2023)
- 4. Apache Hadoop YARN Documentation [Электронный ресурс]. URL: https://hadoop.apache.org/docs/current/hadoop-yarn/hadoop-yarn-site/YARN.html (дата обращения: 30.12.2023)
- 5. Apache Airflow Documentation [Электронный ресурс]. URL: https://airflow.apache.org/docs/ (дата обращения: 30.12.2023)
- 6. Хабр. Все, что вам нужно знать об Airflow DAGs, ч.1 Основы и расписания [Электронный ресурс]. URL: https://habr.com/ru/articles/682384/ (дата обращения: 30.12.2023)
- 7. mrjob v0.7.4 documentation [Электронный ресурс]. URL: https://mrjob.readthedocs.io/en/latest/ (дата обращения: 30.12.2023
- 8. pandas 2.1.4 documentation [Электронный ресурс]. URL: https://pandas.pydata.org/docs/ (дата обращения: 30.12.2023)
- 9. Matplotlib 3.8.2 documentation [Электронный ресурс]. URL: https://matplotlib.org/stable/index.html (дата обращения: 30.12.2023)
- 10. Mendel Cooper. Advanced Bash-Scripting Guide [Электронный ресурс]. URL: https://se.ifmo.ru/~ad/Documentation/ABS_Guide_ru.html (дата обращения: 30.12.2023)

Результат работы

Лабораторная работа - https://github.com/staffeev/cs_itmo_project

Видео-демонстрация работы кластера - https://drive.google.com/file/d/16BC8VS1cVjWzKh3D gtd5pA0 921YW1lD/view?usp=sharing

Спасибо за внимание!